

Dự đoán Sụp đổ Giá Cổ phiếu bằng Suy luận Quan hệ theo Thời gian của LLM

Đồ án Big Data · phỏng theo arXiv:2410.17266

Nhóm: [TÊN NHÓM]
Thành viên: [TÊN]
GVHD: [TÊN GV]

Học kỳ / Năm

Vấn đề & Động lực

- Thị trường = dữ liệu **khối lượng lớn, tốc độ cao, đa dạng** → bài toán Big Data tiêu biểu.
- Dự đoán **hướng giá** (tăng/giảm) $\approx$ bất khả thi do thị trường hiệu quả dạng yếu (EMH).
- Nhưng **rủi ro sụp đổ (crash)** mang tín hiệu rõ từ TIN TỨC (tâm lý, sự kiện, lan truyền).
- **Mục tiêu:** Cảnh báo sớm rủi ro — Advisory cho nhà đầu tư / quản trị rủi ro (không phải lệnh mua–bán).

Hướng giá (lên/xuống)


$\approx$ Ngẫu nhiên (EMH)

Rủi ro sụp đổ (tail-risk)

✓ Có tín hiệu từ tin tức

Bài toán (Định nghĩa chính xác)

- **Đầu vào:** Dòng tin tài chính theo ngày cho 6 cổ phiếu: AAPL, AMZN, GOOGL, NVDA, TSLA, NFLX.
- **Đầu ra:** Xác suất P (danh mục equal-weight giảm $\geq 6\%$ trong 3 ngày tới) cho mỗi ngày.
- **Nhãn thực tế:** Từ giá lịch sử OHLCV (ngày gọi là crash nếu Low 3 ngày tới $\leq -6\%$).
- **Đánh giá:** AUROC / PR-AUC.
- **Nhân quả:** Chỉ dùng quá khứ (embargo $\geq$ tầm dự báo 3 ngày).



Ý tưởng cốt lõi: LLM Suy Luận, Không Huấn Luyện

- Mô hình **zero-shot**: KHÔNG huấn luyện lại từ đầu — LLM trực tiếp **đọc và lập luận**.
- Phỏng theo khung TRR (Temporal Relational Reasoning).
- Chỉ sử dụng một **meta-learner nhỏ** học trên các đặc trưng dẫn xuất.
- Chuỗi **giá** lịch sử chỉ đóng vai trò cung cấp nhãn để đánh giá và filter.


KHÔNG
Train Model

≠

LLM SUY LUẬN
Zero-shot

Phương pháp TRR: 4 Pha Xử Lý

- 1 **Brainstorm:** Tin tức $\rightarrow$ Đồ thị tác động (VD: "X tác động $\pm$ lên Y").
- 2 **Memory:** Bộ nhớ phân rã $R = \exp(-t \cdot \lambda)$ — ảnh hưởng của tin xấu nhạt dần theo thời gian.
- 3 **Attention:** PageRank cắt tĩa đồ thị, chỉ giữ top- k cạnh liên quan nhất đến danh mục.
- 4 **Reason:** LLM suy luận trên đồ thị con $\rightarrow$ Trả về xác suất sụp đổ.



RAG: Truy hồi Tăng cường (Retrieval-Augmented Generation)

Vai trò 1: Chọn lọc

Từ kho tin khổng lồ mỗi ngày (hàng triệu bài), chỉ lấy k tin **liên quan chặt chẽ** đến danh mục nhất $\rightarrow$ Giới hạn context cho LLM.


Vai trò 2: Few-shot theo tình huống

Truy hồi các ngày quá khứ tương tự + kết cục thực tế ("đã crash" hoặc "không") và chèn vào prompt để LLM đối chiếu.

- **Kết quả:** Corpus dung lượng lớn nhưng **chi phí LLM vẫn** $O(\text{số_ngày} \times k)$.
- Quá trình hoàn toàn tôn trọng tính nhân quả (chỉ nhìn về quá khứ).

Dữ liệu

- **FNSPID (Nguồn):** 23 GB thô, **15,7 triệu bài**, 4.775 mã cổ phiếu (1999–2023).
- **Corpus lọc (2016–2023):** **4,5 triệu bài / 12 GB**.
- **Giá OHLCV:** 6 mã, 2.012 ngày giao dịch (sinh nhãn crash).
- **Tin trực tiếp:** ~500 tin/ngày (từ yfinance & Google News RSS).



Bốn chữ V của Big Data

Volume (Khối lượng)

23 GB / 15,7 triệu bài thô
→ 12 GB / 4,5 triệu bài sau lọc.

Variety (Đa dạng)

Tin công ty, vĩ mô, crypto, thể giới; Dữ liệu giá (nhiều nguồn phi cấu trúc & cấu trúc).

Velocity (Tốc độ)

Luồng trực tiếp ~500 tin/ngày,
Cập nhật mỗi 60 giây (Spark Streaming).

Value (Giá trị)

Advisory cảnh báo sụp đổ danh mục + Web app triển khai thực tế.

Kiến trúc Lưu trữ: "Lưu khổng lồ, phục vụ tí hon"


- **Lạnh:** Corpus 12 GB lưu trữ trên đĩa cứng.
- **Ấm:** SQLite chỉ mục theo ngày (1,9 GB) cho phép tra cứu 1 ngày trong ~ 44 ms.
- **Nóng:** Lát dữ liệu RAG đã lọc để đưa vào LLM chỉ ~ 2 MB.

Kỹ thuật tối ưu:

- Stream-and-filter: Không nạp toàn bộ 23 GB thô vào RAM.
- Chỉ định dạng cột cần thiết và sử dụng chỉ mục phân vùng.
- **Nguyên tắc:** Dữ liệu dẫn xuất không commit vào Git, chỉ commit code tái tạo (Reproducibility).

Xử lý Phân tán: Apache Spark

- **Spark ETL:** Chuyển corpus 12 GB sang định dạng **Parquet phân vùng theo năm** (chuẩn Data-lake/HDFS).
- Đo lường thực tế:
 - Chuyển đổi 12 GB CSV → **718 MB Parquet** trong 101 giây.
 - Truy vấn **4,5 triệu dòng** từ Parquet mất **2,4 giây** (nhánh hơn $\sim 40\times$, 8 lõi song song).
 - **Partition pruning:** Quét riêng năm 2020 chỉ mất **0,2 giây**.
- Cùng source code có thể chạy cluster thực tế (đổi SPARK_MASTER).



Tính toán Phân tán: Fan-out GPU


- **Điểm nghẽn:** Suy luận của mô hình LLM 32B rất nặng.
- **Giải pháp:** Phân tán thành **40 mảnh (shard)** (20 base + 20 RAG) chạy song song độc lập.
- Chạy trên một **pool GPU Kaggle** → Hoàn thành cả 40 mảnh trong **~20 phút** thay vì ~5 giờ (tuần tự).
- Mỗi shard bao gồm ~101 ngày và một **kho ngày lịch sử đầy đủ** để giữ tính nhân quả (lookback).
- **Lưu ý:** Phân tán ở đây chỉ giúp **TĂNG TỐC**, chạy 1 máy tuần tự vẫn cho KẾT QUẢ Y Hệt.

Mô hình & Triển khai

- **Offline Backtest (Quy mô lớn):** Dùng **Qwen2.5-32B** (Kaggle RTX 6000 Pro) để đánh giá.
- **Suy luận trực tiếp (Live):** Dùng **Qwen2.5-7B-AWQ** (RTX 2060 SUPER 8 GB cục bộ) cho dự đoán thời gian thực.
- **Hệ thống:**
 - **FastAPI:** Các endpoint `/predict`, `/predict-ensemble`, `/backtest`.
 - **Streamlit Web App:** Giao diện giám sát trực tiếp, nạp ~500 tin/ngày và biểu đồ tương tác.
 - **Daemon background:** Crawl và cập nhật mỗi 60 giây, lưu rolling 7 ngày.


Hiển thị $\neq$ Dự đoán

- Giao diện Web hiển thị 4 nhóm tin: Công ty, Vĩ mô, Crypto, Thể giới.
- **Dự đoán mô hình CHỈ DÙNG:** Tin Công ty + Vĩ mô (khớp với phân phối dữ liệu đã huấn luyện).
- Các tin Crypto / Thể giới bị **loại bỏ** hoàn toàn trước khi đi vào LLM suy luận.
- Feed trực tiếp **không có nhãn đánh giá** $\rightarrow$ mục đích để **chứng minh khả năng triển khai thực tế**.



Kết quả (1): Số đã có

- **Cửa sổ COVID (2019–2020):**
 - Base: **0.785**
 - +RAG: **0.847**
- **Cửa sổ rộng (2016–2020):**
 - Base: **0.710**
 - +RAG: tăng **0.074** ($p=0.009$, có ý nghĩa thống kê).
- **Baseline (Khối lượng tin):** ≈ 0.50 (Ngẫu nhiên) $\rightarrow$ Tín hiệu dự đoán đến từ **suy luận ngữ nghĩa**, không phải đếm số lượng.




Kết quả (2): Mở rộng Toàn bộ Corpus 2016–2023

So sánh trên CÙNG cửa sổ:

- **COVID:** Base **0.707** / RAG **0.763** (Cũ: 0.847)
- **2016–2020:** Base **0.693** / RAG **0.681** (Cũ: 0.710)
- **Toàn bộ 2016–2023:** Base **0.615** / RAG **0.652**

Kết luận:

- Lọc theo danh mục giúp **hồi phục mạnh** (từ 0.37 lên 0.76 trong tập COVID).
- Tuy nhiên, sử dụng corpus lớn **không vượt qua** bộ dữ liệu gốc.
- **Bài học:** Trong phân tích tin tức tài chính, *nhiều dữ liệu hơn không đồng nghĩa với kết quả tốt hơn.*



Phân tích Trung thực (Honest Analysis)

Điều đã hoạt động tốt ✓	Giới hạn / Kết quả âm ×
RAG ổn định: Cải thiện dự đoán trong khủng hoảng (COVID).	Small-N: Chỉ có 14–82 ngày crash ($\sim 4\%$), điểm AUROC tuyệt đối cần được đọc thận trọng.
Kiến trúc Big Data: Stream-index-select, Spark ETL + Parquet hiệu quả cao.	Các thử nghiệm thất bại: Graph-RAG đa bước, mạng hướng 3 lớp, đặc trưng OHLCV Volume không tăng hiệu suất.
Phân tán Fan-out: Tối ưu hóa được điểm nghẽn GPU bằng pool Kaggle free-tier.	Bẫy Big Data: Corpus toàn mã làm giảm mạnh tín hiệu (liên quan $\neq$ liên quan danh mục).

Kết luận & Hướng phát triển

- **Đóng góp chính:**

- ➊ Áp dụng thành công mô hình **TRR Zero-shot + RAG** để dự đoán rủi ro sụp đổ chứng khoán từ tin tức văn bản.
- ➋ **Kiến trúc RAG** chứng minh được sự cải thiện ổn định trong các cửa sổ khủng hoảng.
- ➌ Triển khai **hạ tầng Big Data thực tế**: xử lý luồng tin 23 GB bằng kỹ thuật Stream-Index-Select, lưu trữ Parquet qua Spark và phân tán inference bằng pool GPU.

- **Hướng phát triển trong tương lai:**

- Mở rộng sang cluster Spark/HDFS phân tán trên nhiều máy vật lý thực tế.
- Tích hợp corpus đa nguồn (Mạng xã hội, Báo cáo tài chính).
- Hiệu chỉnh ngưỡng xác suất theo bài toán chi phí rủi ro và mở rộng dự đoán đa tài sản.

**Cảm ơn thầy/cô và các bạn đã lắng
nghe!**

Q&A

Mã nguồn Đề án:

`https://github.com/duongtrongnguyen123/bigdata-stock-crash-trr`